

DOCUMENTATION DE LA DÉMARCHE

Mission 1, BottleNeck

Amélioration du livrable du projet 6

Veille métier et technologique, cahier des charges fonctionnel, mini formation pour les métiers, hypothèses, tests, résultats, limites et décisions.

Deux livrables : le notebook Python amélioré (EL_GHRAIRI_Ahmed_1_projet_ameliore_082026.ipynb), exécutable de bout en bout, et le présent document.

Ahmed EL GHRAIRI , Formation Data Analyst, OpenClassrooms

Soutenance le 24 septembre 2026

Sommaire

Introduction : le projet en quelques lignes

Partie 1 , Veille métier et technologique

Partie 2 , Cahier des charges fonctionnel

Partie 3 , Mini plan de formation des métiers

Partie 4 , Organisation du projet et registre des risques

Partie 5 , Hypothèses, tests, résultats, limites, décisions

Partie 6 , Reproductibilité

Partie 7 , Synthèse et prochaines étapes

Annexe A , Journal des expérimentations IA

Annexe B , Grille des indicateurs et localisation des preuves

Annexe C , Captures : suivi de projet et dispositif de veille

Introduction : le projet en quelques lignes

Ce document accompagne le notebook amélioré du projet BottleNeck. Il présente, dans l'ordre, la veille métier et technologique qui a guidé les choix d'outils, le cahier des charges fonctionnel, le mini plan de formation destiné aux métiers, l'organisation du projet et ses risques, puis les hypothèses, les tests, les résultats, les limites et les décisions qui ont jalonné le travail. Les annexes contiennent le journal complet des expérimentations menées avec l'IA, la grille des indicateurs avec la localisation de chaque preuve, et les captures d'écran du dispositif de veille et du suivi de projet.

Les deux livrables de la mission : le notebook Python amélioré, exécutable de bout en bout, et le présent document. L'ensemble du projet, avec ses fichiers sources et son historique, est organisé dans un dépôt dont la structure est décrite en partie 6.

Partie 1. Veille métier et technologique

1.1 Le besoin qui déclenche la veille

Lors du projet 6, une dizaine d'anomalies de données ont été détectées à la main, cellule par cellule : prix négatifs, stocks négatifs, statuts incohérents, références hors format, doublons, correspondances manquantes entre les deux systèmes. Rien ne garantissait que ces vérifications seraient refaites le mois suivant, ni qu'une anomalie d'un type nouveau serait repérée, et personne d'autre que moi ne pouvait relancer ces contrôles sans lire le code.

Besoin formulé : automatiser les contrôles qualité des données à chaque import, avec un résultat lisible par une personne non technique. Un besoin secondaire porte sur l'unification des visualisations destinées au comité de direction.

1.2 Panel de solutions : comparatif et décision

Solution	Cas d'usage type	Avantages	Limites	Prérequis	Décision
Pandera 0.33.1	Valider un tableau pandas contre un schéma de règles : bornes, unicité, types, formats	Léger, règles déclaratives et lisibles, erreurs précises avec les lignes fautes, traitement local. Projet actif, revu par pyOpenSci, 97 % de couverture de tests, 222 M de téléchargements	Ne couvre pas les règles portant sur la relation entre deux tables, pas de rapport visuel intégré	Python 3.10 à 3.14, pandas, une dépendance à figer. Licence MIT, libre d'usage	RETENUE, solution principale
Contrôles pandas assistés par IA	Écrire sur mesure un contrôle que la librairie n'exprime pas, ici le taux de correspondance entre l'ERP et le site	Aucune dépendance ajoutée, souplesse totale, rapide à produire avec un assistant	Qualité dépendante de ma relecture, code non standardisé, risque de code faux d'apparence correcte	Python, pandas, test systématique de chaque contrôle généré	RETENUE, en complément
Great Expectations	Contrôler la qualité de plusieurs sources dans un flux industrialisé, avec rapports partagés	Catalogue de règles éprouvées, rapports détaillés lisibles par des non techniciens	Installation et configuration lourdes, changements d'interface introduits par la version 1.0, surdimensionné pour trois fichiers	Python, configuration d'un contexte de projet, temps d'apprentissage	ÉCARTÉE, à réexaminer
dbt	Tester en SQL des tables déjà chargées dans un entrepôt de données	Tests intégrés au flux de transformation, standard du marché en entrepôt	Suppose une infrastructure absente ici, il faudrait charger les fichiers dans un entrepôt avant tout contrôle	Un entrepôt de données, des connaissances SQL et dbt	ÉCARTÉE, hors périmètre

Justification de la décision, trois raisons par ordre de poids. La solution correspond au format réel des données, qui sont des tableaux pandas en mémoire et non des tables d'entrepôt. Les règles restent lisibles, ce qui compte parce que la personne qui relancera les contrôles chaque mois n'est pas développeuse. Le coût est proportionné : une seule dépendance, un traitement entièrement local donc conforme au RGPD, et aucune infrastructure à maintenir, ce qui répond aussi au critère de sobriété.

Critères appliqués : pertinence au besoin, robustesse de la détection, coût en temps, lisibilité pour un profil non technique, reproductibilité, sécurité et conformité RGPD, sobriété. Cette décision, prise sur dossier lors de la veille, a ensuite été confirmée par l'expérimentation des deux options retenues sur les données réelles du projet (voir partie 5 et notebook, section 1.3).

Visualisations, besoin secondaire. Matplotlib et Seaborn sont retenus pour toutes les figures de restitution, parce qu'elles s'exportent en image fixe et s'intègrent telles quelles dans une présentation. Plotly est conservé pour l'exploration à l'écran uniquement. Le critère décisif est la destination finale des figures : une présentation au comité de direction, pas un tableau de bord interactif.

1.3 Dispositif de veille et automatisation

Trois niveaux de sources : primaires pour décider, secondaires pour comprendre, découverte pour repérer. Règle appliquée : aucune décision technique n'est prise à partir d'une source de découverte seule. Rituel : 20 minutes par semaine sur la newsletter, 30 minutes par mois sur les notes de version, une heure par trimestre pour réexaminer les solutions écartées.

Source	Niveau	Automatisation mise en place	Preuve
Documentation officielle Pandera	Primaire	Consultation à chaque besoin, version relevée et figée dans le projet	Annexe C4
Dépôt GitHub de Pandera	Primaire	Notifications de nouvelles versions activées (Watch, Releases)	Annexe C3
Data Elixir, newsletter hebdomadaire du mardi	Découverte	Abonnement par courriel et libellé Gmail dédié pour isoler la veille de la boîte de réception	Annexe C5
Alerte Google sur mots clés	Découverte	Alerte hebdomadaire, meilleurs résultats uniquement, sur la validation de données en Python	Annexe C7
Compte professionnel data suivi sur LinkedIn	Découverte	Abonnement, contenu pédagogique généraliste sur le métier de data analyst	Annexe C6
CNIL	Primaire	Consultation trimestrielle. Alerte automatique volontairement écartée pour éviter la surcharge d'information	Rituel de veille

Pistes d'amélioration continue : suivre les évolutions de syntaxe de Pandera, l'import passant désormais par le module dédié à pandas ; évaluer la validation en ligne de commande apparue en version 0.33, qui permettrait de lancer les contrôles sans ouvrir le notebook et répondrait directement au besoin d'un utilisateur non technique ; réexaminer Great Expectations si le nombre de sources augmente ; explorer des méthodes de détection d'anomalies plus robustes que l'écart type et l'intervalle interquartile pour les distributions de prix très asymétriques.

Partie 2. Cahier des charges fonctionnel

2.1 Contexte et parties prenantes

BottleNeck vend du vin en ligne. Ses informations produits sont réparties entre un ERP, qui porte les références, les prix et les stocks, et un site WordPress, qui porte les fiches et les quantités vendues. Les identifiants diffèrent d'un système à l'autre et une table de liaison, tenue à la main, sert de passerelle. L'environnement est complexe, parce qu'il combine trois sources hétérogènes, et changeant, parce que la qualité du rapprochement dépend d'une saisie humaine non contrôlée et que de nouveaux produits arrivent en continu. Un projet de visualisation est prévu ensuite et s'appuiera sur ce travail.

Partie prenante	Décisions prises grâce à l'analyse
Comité de direction	Orienter l'assortiment, arbitrer sur les catégories, juger du montant immobilisé en stock, décider des marges à retravailler
Nicolas, responsable vente	Relancer ou arrêter des références, faire corriger prix et stocks erronés, préparer le projet de visualisation
Stagiaire chargé de la table de liaison	Compléter et corriger les correspondances à partir des anomalies remontées
Moi, analyste	Rapprocher les sources, détecter et documenter les anomalies, produire les analyses et les recommandations

2.2 Problématique, enjeux et priorités

BottleNeck ne parvient pas à piloter son activité de façon fiable. Ses données produits, ventes et stocks sont réparties dans trois fichiers non reliés et sans règles de saisie, ce qui l'empêche de mesurer la performance réelle de son assortiment et de ses stocks, et l'expose à des décisions stratégiques fondées sur des chiffres erronés.

Questions aujourd'hui sans réponse fiable : quelles gammes génèrent réellement le chiffre d'affaires, où dort l'argent immobilisé en stock, quels produits performants risquent la rupture, quels prix et quelles marges sont manifestement faux.

1. **La fiabilité des données**, car une analyse fondée sur des données fausses produit des décisions fausses avec l'apparence de la rigueur.
2. **Les analyses de pilotage**, qui portent la valeur visible du projet.
3. **La reproductibilité**, indispensable à la relance mensuelle mais inutile si les deux premiers points ne sont pas tenus.

2.3 État actuel et périmètre

État actuel. Le notebook du projet 6 charge les trois fichiers, nettoie les données, réalise les jointures et produit les analyses demandées. Trois faiblesses justifient sa reprise : les contrôles qualité sont manuels et non rejouables, la conformité RGPD n'est pas traitée alors qu'elle est demandée, et le notebook n'est pas reproductible faute de chemins relatifs, de versions figées et d'instructions d'exécution.

Traité. Les trois exports d'octobre. Les analyses de stock sur les 825 références de l'ERP, y compris celles sans page web, puisqu'elles immobilisent de l'argent. Les analyses de chiffre d'affaires et de marge sur les 714 références disposant d'une correspondance web, seule population pour laquelle une quantité vendue existe. La détection, la documentation et la correction des anomalies au sein de l'analyse.

Non traité. Toute période hors octobre, ce qui exclut tendance, saisonnalité et prévision. Le chiffre d'affaires des 111 références sans correspondance web. Toute donnée personnelle ou client : la seule colonne à caractère personnel de l'export web est écartée par minimisation. La correction directe des systèmes sources, sur lesquels je n'ai aucun accès en écriture : je recommande, je n'applique pas.

2.4 Contraintes

- **Données.** Exports artisanaux sans contrôle de saisie, anomalies constatées de plusieurs natures, identifiants hétérogènes entre les deux systèmes, un seul mois disponible.
- **Organisation.** Dépendance à une table de liaison maintenue manuellement, travail sur exports figés sans accès aux systèmes, restitution destinée à un public non technique.
- **Technique et réglementaire.** Outillage gratuit et open source, aucun budget logiciel. Respect du RGPD : minimisation, aucune donnée réelle transmise à un service en ligne.

2.5 Critères d'acceptation

Chaque critère est vérifiable par un chiffre ou par oui ou non. L'objectif n'est pas de prouver une exactitude absolue, qu'aucune source extérieure ne permettrait de vérifier, mais que la méthode est explicite et donne toujours le même résultat.

Niveau	Critères
Qualité des données	Aucun prix ni stock négatif dans le jeu final. Cohérence totale entre statut et quantité de stock. Aucun doublon sur les clés. Format des références contrôlé et exceptions tranchées. Taux de non-correspondance mesuré et expliqué à chaque exécution, référence actuelle 111 sur 825 soit 13,5 %, avec alerte en cas de hausse. Règles de saisie formalisées et implémentées en contrôles automatiques.
Analyses	Chiffre d'affaires total et par produit reproductible à l'euro près sur un périmètre explicite, référence 143 680,10 €. Mois de stock et valorisation calculés sur 825 références, au prix de vente et au prix d'achat. Valeurs aberrantes identifiées par deux méthodes, écarts expliqués, chaque cas tranché entre erreur et produit haut de gamme. Taux de marge sur base hors taxes documentée, marges négatives signalées. Corrélations sur l'ensemble des variables demandées.
Opérationnel	Notebook exécutable intégralement sans erreur depuis un environnement vierge. Relance possible le mois suivant par une personne non technique en suivant les instructions. Rapport de contrôles lisible en français sans lecture de code. Toutes les anomalies tracées dans un tableau avec correction et recommandation. Aucune colonne à caractère personnel dans le jeu final.

2.6 Livrables, jalons et ressources

Jalon	Contenu	Condition de validation
J1 : 24 août	Besoin métier et cahier des charges	Relu par une personne extérieure, validé par le mentor
J2 : 26 août	Veille et choix des solutions	Chaque option comparée dispose de sources datées
J3 : 28 août	Organisation du projet et registre des risques	Tableau de suivi alimenté et daté

Jalon	Contenu	Condition de validation
J4 : 2 septembre	Notebook amélioré et journal des essais	Réexécution complète sans erreur
J5 : 3 septembre	Plan de formation et documentation finale	Chaque indicateur couvert par une preuve localisée
J6 : 24 septembre	Soutenance	Présentation tenue deux fois dans le temps imparti

Livrables. Le notebook amélioré, et la présente documentation réunissant le cadrage, la veille, le plan de formation, l'organisation du projet, le journal des essais et les annexes.

Ressources et budget. Une personne, une dizaine de journées estimées. Aucun budget logiciel : tous les outils utilisés sont gratuits. Le coût se limite au temps passé.

Ce que je ne peux pas garantir. Le rapprochement complet des références, qui dépend d'une table que je ne maintiens pas : je m'engage à le mesurer et à le suivre, pas à le supprimer. Et l'exactitude des corrections appliquées, qui reposent sur des hypothèses explicitées et ne remplacent ni un inventaire ni un contrôle de saisie dans l'ERP.

Partie 3. Mini plan de formation des métiers

3.1 Les publics et leurs objectifs

Public	Objectif à l'issue de la formation
Comité de direction	Lire les indicateurs de pilotage (chiffre d'affaires, marges, stock immobilisé) sans ouvrir le notebook
Nicolas, responsable vente	Lire le rapport de contrôles qualité et savoir à qui transmettre chaque type d'anomalie
Responsable de la table de liaison	Relancer seul le notebook avec les nouveaux exports du mois et réagir à une alerte

3.2 Format par public

Comité de direction. Un atelier de 30 minutes, intégré à une réunion existante. Contenu : lecture du chiffre d'affaires par produit, repérage de l'argent immobilisé en stock, identification des catégories à faible marge, sans code ni notebook. Support : le fichier Excel exporté par le notebook, accompagné d'une fiche d'une page définissant chaque indicateur en langage simple et précisant ce qu'un chiffre inhabituel doit déclencher comme question.

Nicolas. Une session d'une heure en tête-à-tête, notebook ouvert à l'écran : exécution ensemble, lecture commentée du rapport de contrôles et de l'alerte sur le taux de correspondance, prise en main du tableau récapitulatif des anomalies, répartition des corrections à transmettre (prix et stock vers l'ERP, références manquantes vers le responsable de la liaison). Support : le README du projet, complété d'un paragraphe sur la conduite à tenir quand le rapport signale une anomalie.

Responsable de la table de liaison. Une session d'une heure trente en binôme, suivie d'un essai en autonomie supervisé à distance : emplacement des nouveaux exports, exécution complète du notebook, lecture du taux de non-correspondance et de l'alerte, conduite à tenir en cas de hausse. Support : un guide pas à pas d'une page, illustré de captures d'écran.

3.3 Accessibilité

Le principe d'accessibilité est appliqué concrètement sur les trois supports, en référence aux exigences du RGAA (référentiel général d'amélioration de l'accessibilité) sur les contrastes et sur l'usage de la couleur.

- Contrastes suffisants et police lisible sur toutes les fiches et guides.
- Aucune information portée par la couleur seule : dans le rapport de contrôles, une anomalie est toujours désignée par du texte.
- Chaque graphique du notebook porte un titre et des étiquettes explicites, lisibles indépendamment de la légende de couleurs.

- Les guides existent en version texte simple et imprimable, en plus des captures d'écran, pour rester utilisables avec un lecteur d'écran.
- Le rythme des sessions est adaptable : un temps de reprise est prévu si le premier essai en autonomie ne suffit pas.

3.4 Évaluation

Comité de direction et Nicolas : pas d'évaluation formelle, la formation est validée par l'usage autonome des supports dans les semaines suivantes.

Responsable de la table de liaison : une mise en situation réelle plutôt qu'un questionnaire. Il relance seul le notebook le mois suivant avec les nouveaux exports ; la formation est réussie si le rapport de contrôles sort sans erreur et si le taux de correspondance est correctement interprété.

Partie 4. Organisation du projet et registre des risques

4.1 Découpage en lots

Lot	Contenu	Livrable produit
L1. Cadrage	Parties prenantes, problématique, périmètre, contraintes, critères d'acceptation	Cahier des charges (partie 2)
L2. Veille	Besoin de veille, panel de solutions, critères, comparatif, décision, dispositif et automatisation	Veille (partie 1) et preuves (annexe C)
L3. Audit et contrôles	Mise en place des contrôles qualité automatisés, tableau récapitulatif des anomalies, section RGPD	Bloc de contrôles dans le notebook
L4. Analyses	Compléments d'analyse, unification de la charte graphique, reproductibilité	Notebook amélioré
L5. Documentation	Journal des essais, hypothèses et décisions, plan de formation, README	Le présent document
L6. Restitution	Support de présentation et répétitions	Soutenance

4.2 Backlog, estimation et définition de Done

Le backlog est tenu dans un tableau Kanban en ligne, avec cinq colonnes suivant le flux du travail : Backlog, À faire, En cours, En revue, Terminé. Chaque carte porte une estimation de charge par code couleur, vert pour moins de deux heures, orange pour une demi-journée, rouge pour une journée ou plus. Chaque carte active porte dans sa description une condition de passage en Terminé, par exemple pour la veille : chaque option comparée dispose de sources datées, le tableau comparatif est rempli et la décision est justifiée par écrit. Trois captures datées du tableau, au début, au milieu et à la fin du projet, attestent du suivi réel (annexe C).

Dépendances principales. Le lot L3 ne peut pas démarrer avant la décision de veille du lot L2. Le lot L5 dépend de l'achèvement de L3 et L4, puisqu'il documente ce qui a été fait. Le lot L6 dépend de tous les autres.

Tableau en ligne : trello.com/b/inuaH0A2/mission-1-bottleneck-ia (accès public, sans connexion requise).

4.3 Jalons et points de contrôle

Les six jalons J1 à J6 et leurs conditions de validation sont détaillés au cahier des charges, section 2.6. Points de contrôle transverses : relecture par une personne extérieure au jalon J1, réexécution complète du notebook sans erreur avant chaque dépôt, et grille des indicateurs tenue à jour avec la localisation de chaque preuve (annexe B).

4.4 Registre des risques

Sept risques identifiés. La probabilité et l'impact sont évalués sur trois niveaux : faible, moyen, élevé.

Risque	Prob.	Impact	Parade
La table de liaison se dégrade et le taux de non-correspondance augmente au prochain export	Élevée	Élevé	Mesurer le taux à chaque exécution et le comparer à la référence de 13,5 %. Déclencher une alerte en cas de hausse. Transmettre au responsable de la table la liste des références non rapprochées.

Risque	Prob.	Impact	Parade
L'assistant IA produit du code qui semble correct mais ne l'est pas	Élevée	Élevé	Tester chaque contrôle généré sur un cas dont le résultat est connu à l'avance, avant intégration. Consigner l'essai et son résultat dans le journal. Ne jamais intégrer un code non testé.
Une donnée réelle est transmise à un service en ligne par inadvertance	Moyenne	Élevé	Règle écrite en tête du journal des essais : ne transmettre que la structure, noms de colonnes, types et valeurs fictives. Ne jamais joindre de fichier source ni copier un extrait de données réelles.
La correction des stocks négatifs masque un dysfonctionnement au lieu de le signaler	Moyenne	Moyen	Un stock négatif traduit un excès de sorties enregistrées : double scan en caisse, démarque saisie plusieurs fois, erreur de comptage. Conserver la trace de chaque valeur corrigée, transmettre les références concernées avec recommandation d'inventaire physique, et distinguer l'écart significatif de l'incident isolé.
Le notebook ne s'exécute pas sur une autre machine que la mienne	Élevée	Élevé	Chemins relatifs uniquement, versions figées dans un fichier de dépendances, cellule d'environnement en tête de notebook, et test de réexécution complète avant chaque jalon.
Une mise à jour de la librairie de validation casse le code avant la soutenance	Faible	Moyen	Figurer la version installée et l'inscrire dans le fichier de dépendances. Les notifications de nouvelles versions permettent d'anticiper, mais aucune montée de version n'est effectuée entre le dernier test et la soutenance.
Retard sur les trois tâches longues identifiées au backlog	Moyenne	Moyen	Traiter les tâches dans l'ordre des priorités du cahier des charges : fiabilité, puis analyses, puis reproductibilité. En cas de retard, réduire l'ampleur des compléments d'analyse plutôt que celle des contrôles qualité, qui portent la valeur du projet.

Partie 5. Hypothèses, tests, résultats, limites, décisions

Pour chaque amélioration significative apportée à la version initiale, ce tableau retrace le raisonnement complet : ce que je supposais, comment je l'ai vérifié, ce que j'ai trouvé, ce que je ne peux pas garantir, et la décision prise. Le détail des essais menés avec l'IA est en annexe A.

Sujet	Hypothèse	Test réalisé	Résultat	Limite	Décision
Prix négatifs	Erreur de signe à la saisie	Vérification que les valeurs absolues restent cohérentes avec la fourchette de prix de la catégorie	Cohérent pour les 3 cas	Ne peut pas exclure un avoir ou une remise mal saisie	Correction en valeur absolue, signalée à l'ERP
Stocks négatifs	Excès de sorties enregistrées (double scan, démarque saisie plusieurs fois, erreur de comptage)	Distinction entre un écart de -10 (à vérifier) et un écart de -1 (probable incident isolé)	Deux cas, deux amplitudes différentes	Sans accès au système de caisse, la cause exacte reste une hypothèse	Stock ramené à 0, recommandation d'inventaire physique transmise
Choix de l'outil de contrôle	Une librairie déclarative sera plus lisible qu'un code écrit à la main	Comparaison de Pandera et de contrôles pandas sur les données réelles, avec test sur des cas connus	Les deux options retrouvent les mêmes anomalies ; Pandera est plus lisible, pandas gère mieux les règles inter-tables	Pandera ne couvre pas les règles entre deux tables	Pandera en solution principale, pandas en complément
Contrôle automatisé des ventes	La revue manuelle a pu manquer des anomalies	Ajout d'une règle sur les ventes négatives dans le contrôle automatisé	2 lignes détectées, absentes de la revue manuelle initiale	Cause exacte non vérifiable sans accès au système de vente	Anomalie ajoutée au tableau récapitulatif
Taux de correspondance ERP / web	Ce taux peut se dégrader si la table de liaison n'est pas mise à jour	Mesure à chaque exécution, comparaison à la référence d'octobre (13,5 %)	Taux stable sur les données d'octobre, mécanisme d'alerte fonctionnel	Ne peut pas empêcher la dégradation, seulement la détecter	Alerte automatique et export de la liste concernée
Colonne post_author	Donnée à caractère personnel sans utilité pour l'analyse	Inventaire des 29 colonnes de l'export, vérification de son contenu	Confirmé : identifiant d'utilisateur WordPress, aucun lien avec l'analyse	Aucune	Colonne écartée par principe de minimisation
Valorisation du stock	La valorisation au prix de vente seule est insuffisante	Calcul d'une seconde valorisation au prix d'achat	532 119,10 € au prix de vente contre 298 627,66 € au prix d'achat	Le premier est TTC, le second HT : ordre de grandeur, pas une marge	Les deux valorisations conservées et distinguées

Limites transverses, à garder en tête pour toute lecture des résultats. Un seul mois de données : aucune tendance, saisonnalité ou prévision ne peut en être tirée, et un produit sans vente en octobre n'est pas nécessairement un produit sans vente. La TVA est supposée uniforme à 20 % pour toutes les références taxables. Une corrélation mesure une association, pas une cause. Le code assisté par IA a été testé sur les cas connus, pas prouvé dans l'absolu : un type d'anomalie absent d'octobre et absent des règles ne serait pas détecté, les règles doivent donc évoluer avec les anomalies rencontrées.

Partie 6. Reproductibilité

Structure du dépôt : data/ (les trois fichiers sources), notebooks/ (version initiale conservée et version 2), docs/ (la présente documentation et la grille des indicateurs), logs/ (journal des expérimentations IA), outputs/ (fichiers générés par le notebook : exports Excel et figures), requirements.txt, README.md.

Environnement testé : Python 3.13.9, pandas 2.2.3, numpy 2.1.3, pandera 0.33.1, matplotlib 3.10.0, seaborn 0.13.2, plotly 5.24.1, openpyxl 3.1.5. Les versions exactes sont figées dans requirements.txt.

Instructions d'exécution : installer les dépendances avec pip install -r requirements.txt, déposer les trois fichiers Excel dans data/, ouvrir le notebook et exécuter Redémarrer et tout exécuter. Le notebook a été testé de cette façon avant le dépôt, sans erreur.

Relance mensuelle : remplacer les trois fichiers dans data/ en conservant les mêmes noms, relancer le notebook, lire le rapport de contrôles (section 1.3 du notebook) et l'alerte sur le taux de correspondance (section 3.2) avant d'utiliser les résultats, puis transmettre le fichier recap_anomalies.xlsx à Nicolas et la liste des références sans correspondance au responsable de la table de liaison.

Partie 7. Synthèse et prochaines étapes

Ce projet reprend une analyse de données existante pour une entreprise de vente de vin en ligne et l'améliore de façon critique et documentée à l'aide de l'intelligence artificielle. Le point de départ était un jeu de trois fichiers non reliés, avec des erreurs de saisie non détectées et aucun contrôle automatisé. J'ai formalisé le besoin métier et un cahier des charges, mené une veille comparant quatre solutions de contrôle qualité des données, puis implémenté un dispositif automatisé qui vérifie les données à chaque import et produit un rapport lisible par un profil non technique. Ce dispositif a détecté une anomalie que la revue manuelle n'avait pas vue. Chaque décision technique est documentée, y compris les solutions écartées et pourquoi, ainsi que les limites de ce que je peux garantir. Le projet respecte le RGPD par minimisation des données et est reproductible sur un poste tiers.

Prochaines étapes recommandées : compléter la table de liaison pour réduire le taux de non-correspondance, connecter les contrôles qualité directement aux exports pour une exécution sans notebook (la validation en ligne de commande de Pandera 0.33 est la piste prioritaire), et utiliser ce jeu de données nettoyé comme base du futur projet de visualisation.

Annexe A. Journal des expérimentations IA

Règles que je m'impose. Tout prompt utilisé pour ce projet est consigné ici, y compris ceux dont le résultat est écarté. Aucune donnée réelle de BottleNeck n'est envoyée à un outil IA en ligne : je transmets la structure, jamais les fichiers. Tout code proposé par une IA est testé avant d'être intégré au notebook.

Critères d'évaluation utilisés : exactitude après test, exhaustivité, temps passé, lisibilité et maintenabilité, reproductibilité, sécurité et RGPD, sobriété.

Essai n°1 (30 août 2026) : choisir l'outil pour automatiser les contrôles qualité des données

Outil : Claude (Anthropic), version web

Prompt : *Agis en tant qu'architecte Data expérimenté. Je dois automatiser les contrôles de qualité de données sur un volume restreint (3 fichiers CSV/DataFrames pandas en mémoire, pas d'entrepôt de données type Snowflake/BigQuery). Compare brièvement les options (dbt, Pandera, Great Expectations, pandas pur) et recommande la solution la plus sobre et pertinente. Format attendu : un tableau comparatif rapide (forces/faiblesses/prérequis) suivi d'une recommandation finale argumentée.*

Variante testée : aucune, question ouverte

Résultat : Comparaison de quatre options. dbt écarté parce qu'il suppose un entrepôt de données ; Great Expectations écarté parce que surdimensionné pour trois fichiers.

Critères : pertinence au format des données, lisibilité pour un profil non technique, sobriété

Décision : Gardé. Pandera comme solution principale, contrôles pandas en complément pour les règles inter-tables. Pourquoi : La réponse correspondait à ce que je connaissais de dbt (vu en formation sur Snowflake) et l'argument de l'entrepôt était vérifiable.

Essai n°2 (1er septembre 2026) : générer le schéma Pandera des règles de l'ERP**Outil :** Claude (Anthropic)**Prompt :** *Agis en tant qu'ingénieur Data spécialisé en validation de données. Analyse le notebook joint et génère un schéma de validation Pandera (DataFrameSchema) robuste pour les données ERP. Règles métier à couvrir : détecte les prix négatifs, les stocks négatifs et les incohérences de statut.***Variante testée :** v1 : colonnes texte déclarées avec le type str. v2 : colonnes texte déclarées sans type, contrôlées uniquement par des règles Check**Résultat :** La v1 dépend de la version de pandas (type object en pandas 2, type str en pandas 3) et risque d'échouer selon la machine. La v2 fonctionne sur les deux et retrouve les trois prix négatifs, les deux stocks négatifs et les deux incohérences de statut.**Critères :** exactitude sur les cas connus, reproductibilité sur une autre machine**Décision :** **Gardé v2, écarté v1. Pourquoi :** La reproductibilité est un critère d'acceptation du cahier des charges ; un schéma qui casse selon la version de pandas ne l'est pas.**Essai n°3 (1er septembre 2026) : transformer la sortie technique de Pandera en un rapport lisible****Outil :** Claude (Anthropic)**Prompt :** *À partir des résultats d'exécution du schéma Pandera, écris une fonction Python qui transforme les erreurs techniques en un rapport de synthèse lisible par un profil non technique. Présente un tableau récapitulatif : règle, nombre de lignes en anomalie, exemples d'identifiants. Attention au comptage : pour les règles de table multi-colonnes, regroupe les anomalies par règle uniquement.***Variante testée :** v1 : regroupement des anomalies par colonne et par règle. v2 : les règles de table regroupées par règle seule**Résultat :** La v1 comptait six fois la même anomalie pour la règle de cohérence statut / quantité, une fois par colonne de la table, alors qu'il n'y a que deux lignes en défaut. La v2 donne le bon comptage.**Critères :** exactitude, lisibilité du rapport**Décision :** **Gardé v2, écarté v1. Pourquoi :** Un rapport qui gonfle les comptages perd toute crédibilité auprès de Nicolas.**Essai n°4 (3 septembre 2026) : écrire les mêmes règles en pandas pur (option B) pour comparer avec Pandera****Outil :** Claude (Anthropic)**Prompt :** *Rédige les mêmes règles de contrôle qualité sous forme de fonctions pandas pures (sans bibliothèque externe), afin de comparer cette approche avec Pandera. Gestion des nuls : pour l'unicité des identifiants, combine duplicated() et isna(). Sortie : restitue un dictionnaire d'anomalies avec exactement la même structure de comptage que celle obtenue avec Pandera.***Variante testée :** v1 : règle d'unicité écrite avec duplicated() seul. v2 : duplicated() | isna() pour prendre aussi les identifiants manquants**Résultat :** La v1 laissait passer un identifiant manquant sans le signaler. La v2 corrigée passe le test sur les cas connus et donne les mêmes comptages que Pandera sur les six règles communes.**Critères :** exactitude, lisibilité des règles, maintenabilité**Décision :** **Gardé v2 en complément uniquement, pour la règle inter-tables du taux de correspondance. Pourquoi :** Les masques booléens se lisent mal et chaque nouvelle règle demande un nouveau test ; le schéma Pandera se lit comme une liste de contraintes.**Essai n°5 (3 septembre 2026) : vérifier les deux options sur des cas dont le résultat est connu****Outil :** Claude (Anthropic) pour écrire les assertions, exécution sur les données réelles en local**Prompt :** *Rédige une suite de tests unitaires (avec assert Python) pour vérifier la cohérence des contrôles entre la version Pandera et la version pandas pur sur nos données réelles. Ajouter un contrôle sur la colonne des quantités vendues de l'export web pour détecter d'éventuelles valeurs négatives non identifiées lors de la revue manuelle.***Variante testée :** aucune**Résultat :** Les deux options retrouvent 3 prix négatifs, 2 stocks négatifs, 2 incohérences et 3 identifiants hors format. Le contrôle révèle en plus deux quantités vendues négatives dans l'export web, que la revue manuelle du projet 6 n'avait pas vues.

Critères : exactitude

Décision : **Gardé. Anomalie nouvelle ajoutée au tableau récapitulatif.** **Pourquoi :** C'est la preuve que le contrôle automatisé apporte quelque chose que la revue manuelle ne fait pas.

Annexe B. Grille des indicateurs et localisation des preuves

Chaque indicateur attendu, avec la localisation exacte de la preuve dans les livrables. NB = notebook version 2, Doc = le présent document.

B.1 Veille technologique et méthodologique

Indicateur	Preuve	Statut
La veille sélectionne, évalue et justifie les choix des solutions techniques	Doc partie 1.2 : comparatif à six colonnes et décision justifiée	Réalisé
La veille soutient une démarche d'optimisation et d'amélioration continue	Doc partie 1.3 : pistes d'amélioration, solutions écartées à réexaminer, rituel trimestriel	Réalisé
Les informations sont fiables et sourcées	Doc partie 1.3 et annexe C : documentation officielle avec version visible, dépôt GitHub, sources datées	Réalisé
Cohérence avec les principes de développement durable	Critère de sobriété appliqué dans le comparatif (partie 1.2) et dans le choix des alertes (partie 1.3)	Réalisé
Au moins un élément d'automatisation de veille	Trois automatisations : notifications GitHub, newsletter, alerte hebdomadaire (annexe C)	Réalisé
Au moins un outil/méthode pertinent et adapté aux besoins des utilisateurs	Doc partie 1.2 : lisibilité des règles ; POC dans le notebook, section 1.3	Réalisé
Besoins en formation des publics non techniques identifiés (dont handicap)	Doc partie 3, avec volet accessibilité (3.3)	Réalisé
Impacts des nouveaux outils identifiés, évalués, expérimentés et documentés	NB sections 1.3 et 6 + annexe A + Doc partie 5	Réalisé

B.2 Identifier le besoin métier

Indicateur	Preuve	Statut
Prise en compte d'un environnement complexe et changeant	Doc partie 2.1 et 2.4	Réalisé
Besoin métier reformulé avec contraintes et spécificités fonctionnelles	Doc parties 2.2, 2.3 et 2.4	Réalisé
Éléments prioritaires identifiés	Doc partie 2.2	Réalisé
Objectifs et enjeux clarifiés, projet cadré	Doc parties 2.2 et 2.5	Réalisé

B.3 Formaliser le cahier des charges fonctionnel


Indicateur	Preuve	Statut
État actuel, spécificités fonctionnelles, ressources et budget décrits	Doc parties 2.3, 2.5 et 2.6	Réalisé
Périmètre décrit (jalons, livrables, planning)	Doc parties 2.3 et 2.6	Réalisé
Document clair et synthétique	Structure en 7 parties et 3 annexes, sommaire, tableaux de synthèse	Réalisé
Bonnes pratiques bureautiques	Page de garde, sommaire, en-têtes et pieds de page, pagination, annexes séparées	Réalisé

B.4 Points attendus par l'énoncé de la mission

Élément attendu	Preuve	Statut
Organisation du projet : lots, backlog, jalons, points de contrôle, registre des risques	Doc partie 4 + tableau Trello en ligne + captures datées (annexe C)	Réalisé
Documentation soignée : traçabilité IA, justifications, limites, reproductibilité, synthèse	Annexe A, Doc parties 5, 6 et 7, notebook	Réalisé

Annexe C. Captures : suivi de projet et dispositif de veille

Toutes les captures sont datées par leurs fichiers dans le dépôt (dossier docs/). Les captures C1 et C2 montrent la progression réelle du tableau de suivi ; une troisième capture, en fin de projet, est jointe dans le dépôt.



C1. Tableau de suivi au démarrage du projet : les cinq colonnes créées, aucune carte.



C2. Tableau de suivi en cours de projet : backlog constitué, estimations par couleur, veille en cours, cadrage en revue.

unionai-oss / pandera

Code Issues 390 Pull requests 46 Agents Discussions Actions Projects Security and quality Insights

pandera Public

Sponsor Unwatch 21 Fork 437 Star 4.4k

main 37 Branches 129 Tags

Go to file Add file Code

Dev-IL AI: add a "Backward Compatibility" section to AGENTS.md (#2461) ✓ b35d29c · 8 hours ago 1,228 Commits

.github	ci: always run linters, regardless of changed paths (#2462)	17 hours ago
adrs	fix: restore optional-column semantics for bare T None ann...	2 days ago
asv_bench	fix(narwhals): SchemaWarning guard, stacklevel calibration, a...	3 months ago
docs	feat(polars): add support for nested DataFrameModel validati...	20 hours ago
pandera	feat(polars): add support for nested DataFrameModel validati...	20 hours ago
scripts	ci: only run unit tests for changed areas (#2450)	4 days ago
specs	fix(narwhals): SchemaWarning guard, stacklevel calibration, a...	3 months ago
tests	feat(polars): add support for nested DataFrameModel validati...	20 hours ago
.coveragerc	update mypy plugin and tests (#1007)	4 years ago
.git-blame-ignore-revs	Update .git-blame-ignore-revs to add Ruff refactor (#2199)	8 months ago
.gitignore	fix(docs): make intersphinx fetch resilient to transient failures ...	4 days ago

About

A light-weight, flexible, and expressive statistical data testing library

www.union.ai/pandera

assertions data-assertions

data-check data-cleaning

data-processing data-validation

data-verification dataframe-schema

dataframes hypothesis-testing

pandas pandas-dataframe

pandas-validation pandas-validator

schema testing testing-tools

validation

Readme

MIT license

Code of conduct

Contributing

C3. Notifications de nouvelles versions activées sur le dépôt GitHub de Pandera (bouton Unwatch : abonnement actif).

 New in Pandera 0.33.0: validate schemas from the command line with the [Pandera CLI](#), and validate [PyArrow](#) dataframes natively!



 Search

CTRL K

INTRODUCTION

Welcome to Pandera

 [Try Pandera](#)

[Official Website](#)

BASICS

[DataFrame Schemas](#)

[DataFrame Models](#)

[Series Schemas](#)

[Data Type Validation](#)

The Open-source Framework for Dataset Validation



Data validation for scientists, engineers, and analysts seeking correctness.


TESTS	PASSING	DOCS	PASSING	PYPI	V0.33.1	LICENSE	MIT
 PYOPENSCI	PEER REVIEWED	REPO STATUS	ACTIVE	DOCS	PASSING	COVERAGE	97%
PYTHON	3.10 3.11 3.12 3.13 3.14	DOI	10.5281/ZENODO.3385265				
BENCHMARKED BY	ASV	DOWNLOADS	222M	DOWNLOADS	1.1M	SLACK	

Pandera is a [Union.ai](#) open source project that provides a flexible and expressive API for performing data validation on dataframe-like objects. The goal of Pandera is to make data processing pipelines more readable and robust with statistically typed dataframes.

Dataframes contain information that `pandera` explicitly validates at runtime. This is useful in production critical data pipelines or reproducible research settings. With `pandera`, you can:

 stable


C4. Documentation officielle de Pandera, version 0.33.1 : licence MIT, revue par pyOpenSci, 97 % de couverture de tests.



C5. Courriel de bienvenue de la newsletter Data Elixir, rangé dans le libellé Gmail dédié Veille Data.









I'll teach you

 **1.4+ Million Subscribers**

 **450k+ Followers**

 **200k+ Users**

Content Creator - Founder - Consultant - Speaker



Alex Freberg ✓ · 3e

Founder of AnalystBuilder.com | YouTube "Alex The Analyst" | Not LinkedIn Top Voice

Charleston et périphérie, Caroline du Sud · [Coordonnées](#)

[Become a Data Analyst Here](#)

456 898 abonnés · 500 ou + relations





Analyst Builder

Pub ...

Découvrez qui a consulté votre profil au cours des 365 derniers jours



Premium

Ahmed, essayez Premium gratuitement

[Essai gratuit](#)

Plus de profils pour vous



Luke Barousse · 3e

Data Nerd · YouTuber · Founder of datanerd.tech

[+ Suivre](#)



Messagerie

C6. Compte professionnel data suivi sur LinkedIn (bouton Suivi actif) : source de découverte.



Alertes

Recevez des alertes lorsque du contenu susceptible de vous intéresser est publié sur le Web

🔍 "data validation" python library



Fréquence

Une fois par semaine maximum

Sources

Automatique

Langue

Toutes les langues

Région

Toutes les régions

Nombre de résultats

Seulement les meilleurs résultats

Envoyer à

ahmed.ghr1993@gmail.com

[Mettre à jour l'alerte](#)

[Masquer les options](#)

C7. Alerte Google configurée : fréquence hebdomadaire au maximum, meilleurs résultats uniquement.